

Reconocimiento de Patrones de Pago de Multas Municipales con Técnicas de Aprendizaje Automático

* Un Estudio Comparativo de Modelos de Aprendizaje Supervisado en el Municipio de Ate

1st Roberth Carlos Gonzales Mauricio

Ingeniería Estadística e Informática

Universidad Nacional del Altiplano

Puno, Perú

73814322gm@gmail.com

2nd Cesia Gomez Flores

Ingeniería Estadística e Informática

Universidad Nacional del Altiplano

Puno, Perú

floresgcesi@gmail.com

2nd Fredd Torres CRUZ

Ingeniería Estadística e Informática

Universidad Nacional del Altiplano

Puno, Perú

ftorres@unap.edu.pe

Abstract—Resumen: Este estudio aborda el problema de la morosidad en el pago de multas municipales mediante técnicas de aprendizaje automático supervisado. Se desarrolló un sistema predictivo a partir de un conjunto de datos históricos compuesto por 53,506 registros del municipio de Ate, en Perú. Para el análisis comparativo, se implementaron cuatro modelos de clasificación: Random Forest, Gradient Boosting, Regresión Logística y Support Vector Machine (SVM). Los modelos fueron entrenados con el 80% de los datos y evaluados con el 20% restante para determinar su capacidad predictiva. El modelo Gradient Boosting demostró el mejor desempeño, alcanzando una precisión del 99.27% y un AUC-ROC de 0.9987. Asimismo, el análisis reveló que ciertos tipos de negocios presentan mayores tasas de pago, mientras que las multas de mayor monto tienden a ser menos cumplidas. Estos hallazgos evidencian el valor del aprendizaje automático como herramienta para identificar patrones y optimizar la gestión de multas en el

I. INTRODUCCIÓN

La buena gestión de multas y la optimización forman desafíos importantes y críticos para la administración municipal a nivel nacional, la morosidad persiste en los pagos de las obligaciones, lo que conlleva una grande pérdida de ingresos públicos, [1]. En el municipio de Ate observamos que muchas multas no se pagan, lo que genera pérdidas económicas importantes. Según nuestros datos, más del 30% de las multas quedan impagadas, afectando los ingresos municipales [2].

El aprendizaje automático supervisado es útil como herramienta para analizar grandes volúmenes de datos e identificar patrones complejos [3]. Esto nos permite construir modelos predictivos son capaces de predecir la probabilidad de cumplimiento de pago, que se basa en el análisis de las multas y los infractores. Estudios previos en campos relacionados, como la predicción de morosidad en carteras de crédito, han demostrado la efectividad de estas técnicas, que reportaron mejoras de hasta el 15% en la identificación de riesgos [4]. De igual forma, en el ámbito del análisis del comportamiento fiscal, el aprendizaje automático ha optimizado las estrategias de cobranza y ha contribuido a la reducción de costos operativos [5]. La creciente adopción de la inteligencia artificial

y el aprendizaje automático en el sector público subraya su potencial para transformar la prestación de servicios y la eficiencia administrativa [6].

Este trabajo se centra en diseñar y evaluar un sistema capaz de identificar patrones utilizando los Datos histórica de las multas en el distrito de Ate. El propósito principal es anticipar y predecir el comportamiento de pago de los ciudadanos sancionados. por lo que se llevo a cabo una evaluación comparativa de distintos algoritmos de aprendizaje supervisado, como Random Forest, Gradient Boosting, Regresión Logística y Máquinas de Vectores de Soporte (SVM), con el objetivo determinar cuál ofrece el mejor rendimiento en este caso particular.

La estructura de este trabajo se organiza de la siguiente manera: Las bases que fundamentan la investigación en la Sección 2 Una descripción detallada de la metodología empleada para la adquisición y preprocesamiento de datos, así como para la construcción y evaluación de los modelos en la Sección 3 Los resultados obtenidos de los experimentos en la Sección 4 Las conclusiones y discusión de las implicaciones de los resultados así como la discusión de posibles limitaciones del estudio en la Sección 5 Finalmente, la Sección 6 resume las principales contribuciones del trabajo y señala futuras líneas de investigación.

II. MARCO TEÓRICO

A. Aprendizaje Supervisado

El aprendizaje supervisado es una rama fundamental del aprendizaje automático (Machine Learning) que se dedica a la formación de modelos predictivos a partir de un conjunto de datos dados [3]. En este modelo utilizamos aprendizaje supervisado porque necesitamos predecir si una multa será pagada o no. Básicamente, el algoritmo aprende de ejemplos pasados donde ya sabemos el resultado (si se pagó o no) para después predecir casos nuevos [3]. La propia esencia del aprendizaje supervisado es que el algoritmo aprenda una función que mapee correctamente las de entrada a las de salida,

permitiéndole prever las salidas para nuevas entradas no vistas con anterioridad. En el contexto de este trabajo, el aprendizaje supervisado se emplea para predecir la probabilidad de que una multa sea pagada, donde las características de las multas y los infractores (e.g., tipo de multa, importe, datos demográficos de la infracción, historial de pagos) son las de entrada, y el estado de pago (pagado/no pagado) es la variable de salida a predecir.

Usamos estos algoritmos porque pueden procesar y analizar grandes números de datos, junto con su rendimiento para identificar patrones complejos y relaciones no lineales, lo convierte en una herramienta potente para optimizar la gestión de multas [7]. Diversos estudios demostraron la efectividad de estas técnicas en la predicción de morosidad en gestión de recursos, donde se ha logrado una mejora en la identificación temprana de riesgos, y en el análisis del comportamiento fiscal, lo que ha conducido a la optimización de las estrategias de cobranza y a una reducción de los costos operativos asociados [5], [6].

B. Modelos de Clasificación

Para hacer la predicción del estado de pagos, se evaluaron cuatro modelos.

1) *Random Forest*: El Random Forest es un algoritmo de ensamble basado en la construcción de múltiples árboles de decisión durante la fase de entrenamiento [8]. Es un método de aprendizaje automático que combina la fuerza de muchas ramas de decisión individuales para producir un modelo más robusto y preciso.

2) *Gradient Boosting*: [9]. Gradient Boosting es una técnica muy eficaz en el aprendizaje supervisado, su potencia está en su enfoque de secuencias. Crea una serie de modelos, donde cada modelo se entrena para mejorar las deficiencias de otros modelos [9].

3) *Regresión Logística*: Usado para problemas de clasificación binaria [10]. Su objetivo es estimar la probabilidad de que una instancia de datos pertenezca a un grupo, por lo cual se utiliza una función logística, lo que mapea los valores en un rango de [0, 1], lo que se interpreta como una probabilidad, lo cual se define como:

$$P(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=1}^n \beta_i x_i)}} \quad (2)$$

donde x representa el vector de características de entrada, β_0 es el término de intercepto, y β_i son los coeficientes de regresión que determinan la contribución de cada característica a la probabilidad de pertenencia a la clase positiva.

4) *Support Vector Machine (SVM)*: Las Support Vector Machines (SVM) son modelos de aprendizaje supervisado potentes y versátiles que se emplean para tareas de clasificación y regresión [11]. Los motores de (SVM) buscan el mejor hiperplano para separar clases, esto lo logra maximizando la distancia a los vectores de soporte. En caso de que no se pueda separar en una línea recta SVM usa (FUNCIONES KERNEL) para transformar los datos en un espacio con mayor dimensión, donde se logra la separación lineal.

C. Métricas de Evaluación

La evaluación de diferentes modelos es un paso muy esencial para determinar la efectividad y capacidad de cada modelo [12]. Para ello, se usaron un conjunto de métricas que muestran el desempeño integral de cada modelo.

1) *Precisión General (Accuracy)*: La Precisión General, o Accuracy, mide la proporción de predicciones correctas (tanto positivos como negativos) sobre el número total de predicciones realizadas.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$

donde TP (Verdaderos Positivos) son las instancias positivas correctamente clasificadas, TN (Verdaderos Negativos) son las instancias negativas correctamente clasificadas, FP (Falsos Positivos) son las instancias negativas clasificadas incorrectamente como positivas, y FN (Falsos Negativos) son las instancias positivas clasificadas incorrectamente como negativas.

2) *Precisión (Precision)*: La precisión muestra la relación de predicciones positivas correctas de todos los casos que el modelo identificó como positivo.

$$Precision = \frac{TP}{TP + FP} \quad (4)$$

3) *Recall (Sensibilidad o Exhaustividad)*: El recuerdo, o la sensibilidad, calcula la fracción de positivos reales que el modelo detectó con precisión de todos los positivos genuinos en el conjunto de datos.

$$Recall = \frac{TP}{TP + FN} \quad (5)$$

4) *F1-Score*: el F1-Score es la media equilibrada de precisión e integridad, ofreciendo un compromiso entre ambas medidas.

$$F1 - Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (6)$$

5) *Área bajo la curva ROC (AUC-ROC)*: La curva ROC (Receiver Operating Characteristic) muestra de forma gráfica la relación existente entre la tasa de verdaderos positivos (TPR, que corresponde con Recall) y la tasa de falsos positivos (FPR) para diferentes márgenes de clasificaciones. El Área bajo la curva ROC (AUC-ROC) es la métrica escalar que calcula el rendimiento discriminatorio del modelo en general para distinguir entre las clases positiva y negativa de la variable de respuesta. En este sentido, un mayor valor de AUC-ROC, más cerca de 1, señala que el rendimiento discriminatorio del modelo es mayor, mientras que un AUC-ROC de 0.5, implica que el modelo discrimina igual que lo haría un clasificador aleatorio.

6) *Matriz de Confusión*: La Matriz de Confusión es una tabla que resume de manera concisa el rendimiento de un algoritmo de clasificación en un conjunto de datos de prueba [13]. Permite visualizar el número de verdaderos positivos (TP), verdaderos negativos (TN), falsos positivos (FP) y falsos negativos (FN). Esta matriz es fundamental para realizar un

análisis detallado de los tipos de errores de clasificación que comete el modelo y para identificar las fortalezas y debilidades específicas de su capacidad predictiva.

Estos conceptos fundamentales conforman el andamiaje teórico sobre el cual se diseñó, implementó y evaluó el sistema de reconocimiento de patrones para la predicción del cumplimiento de pago de multas en el municipio de Ate.

III. METODOLOGÍA

la siguiente investigación gira en torno al desarrollo de un modelo predictivo para el comportamiento de pago de las multas municipales del distrito de Ate, para conseguir este modelo se siguió la metodología estructurada de las etapas de adquisición, preprocesamiento y análisis de los datos, entrenamiento y evaluación del modelo, La Figura 1 ilustra de manera esquemática el flujo de trabajo completo del proceso de aprendizaje automático implementado [3].

A. Adquisición y Preprocesamiento de Datos

La investigación se llevó a cabo utilizando un conjunto de datos históricos de las multas administrativas aplicadas a la población del municipio de Ate. inicialmente estuvo compuesto por 53,506 registros y 23 columnas, configurándose como un conjunto de datos que contiene elementos de diferente tipo relacionados con la multa en cuestión (ej. importe, fecha de emisión, tipo de infracción) y el infractor (ej. tipo de documento, tipo de albarán del negocio, zona de residencia). La disponibilidad pública de los datos desde donde ha sido extraído este conjunto de datos puede ser considerado una base de datos agregada que se halla disponible en un repositorio público. (<https://github.com/robert1357/aprendizaje-supervisado>).

El preprocesamiento de datos fue crucial para asegurar la consistencia de los datos [14]. En este proceso se realizó la normalización de las características numéricas utilizando el método de estandarización (Standard Scaler), definido por la ecuación:

$$x' = \frac{x - \mu}{\sigma} \quad (1)$$

donde x' es el valor normalizado, x es el valor original, μ es la media de la característica y σ es la desviación estándar de la característica [15]. Las variables categóricas fueron transformadas a una representación numérica mediante la técnica de One-Hot Encoding [16], creando nuevas columnas binarias para cada categoría. Finalmente, se llevó a cabo un análisis exploratorio de datos (EDA) y un análisis de correlación para identificar las características más relevantes, lo que contribuye a mejorar la eficiencia computacional y el rendimiento del modelo [17].

B. División del Conjunto de Datos

para tener una evaluación optima y confiable de los modelos, el conjunto de datos procesados fue dividido en dos subconjuntos: 80% para entrenamiento y 20% para evaluación, siguiendo prácticas estándar de machine learning [18]. Esta

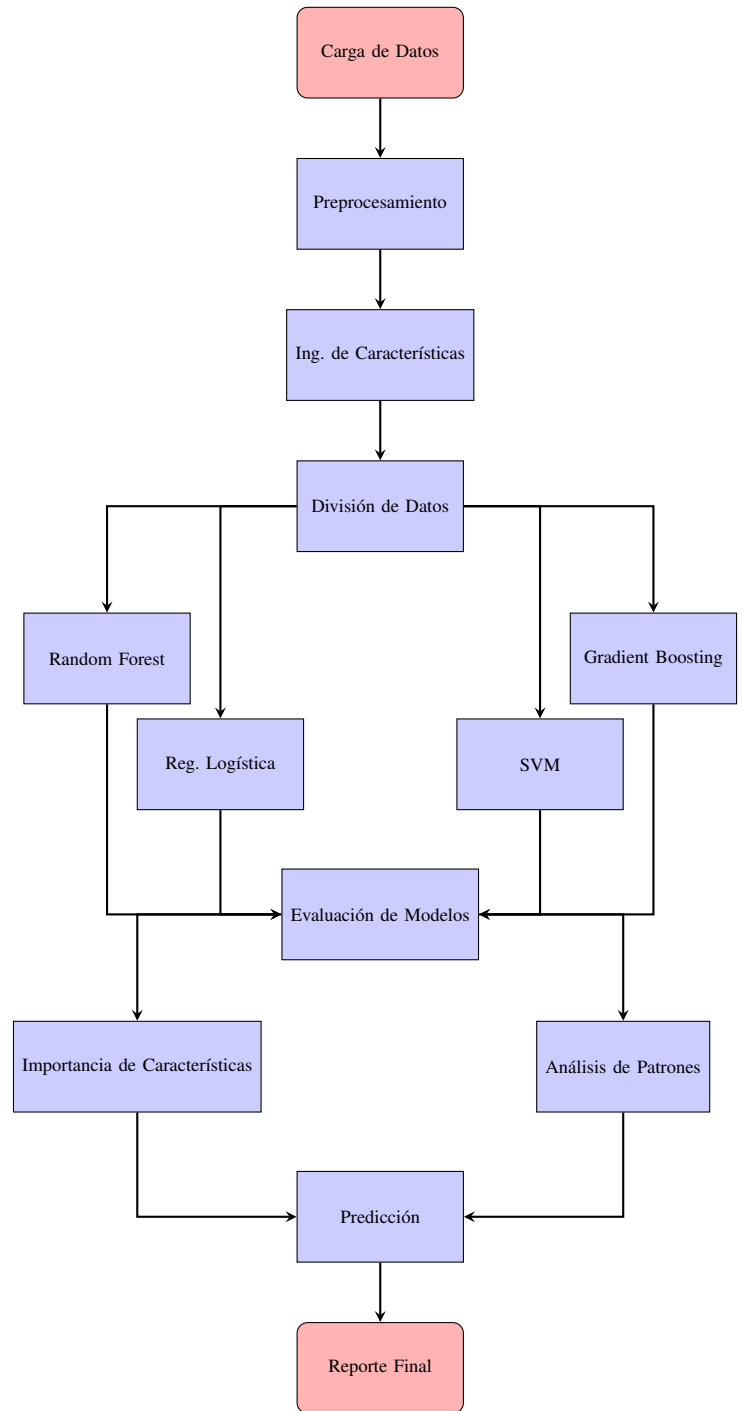


Fig. 1. Diagrama de flujo de la metodología de aprendizaje supervisado para la predicción de pago de multas municipales.

distribución, maximiza la cantidad de datos disponibles para una evaluación exhaustiva del rendimiento del modelo en datos no vistos. El conjunto de evaluación estuvo compuesto por 42,805 registros, de los cuales 17,837 correspondían a multas no pagadas (41.7%) y 24,968 a multas pagadas (58.3%).

TABLE I
MÉTRICAS DE RENDIMIENTO GENERAL DE LOS MODELOS DE
CLASIFICACIÓN

Métrica	Random Forest	Gradient Boosting	Regresión Logística	Support Vector Machine
Accuracy	0.9680	0.9927	0.9854	0.9850
AUC-ROC	0.9966	0.9987	0.9965	0.9973
Precision (Avg)	0.9644	0.9928	0.9858	0.9850
Recall (Avg)	0.9680	0.9927	0.9854	0.9850
F1-Score (Avg)	0.9669	0.9927	0.9850	0.9846

C. Modelos de Aprendizaje Supervisado

Se seleccionaron cuatro modelos de aprendizaje supervisado para ser evaluados en este estudio:

Random Forest Este algoritmo de ensamble se configuró con 100 estimadores, una profundidad máxima de 10 para cada estimador, un mínimo de 5 muestras requeridas para dividir un nodo interno y un mínimo de 2 muestras por raíz terminal. [8].

Gradient Boosting Este modelo secuencial fue configurado con 100 estimadores, una profundidad máxima de 6 para los estimadores de decisión subyacentes y una tasa de aprendizaje de 0.1. La tasa de aprendizaje mide cuánto contribuye cada árbol al modelo final, siendo preferible valores más pequeños para evitar el sobreajuste. [9].

Regresión Logística La simplicidad y capacidad para proporcionar probabilidades directas la hacen una opción fundamental para la clasificación binaria. Su función se define en la ecuación (2) [10]. Dada su naturaleza menos paramétrica en comparación con los modelos de ensamble no se realizaron mas ajustes.

Support Vector Machine (SVM) Para SVM, se utilizó el *kernel* RBF. Este *kernel* permite al modelo mapear las características a un espacio de mayor dimensión, lo que facilita la separación de clases que no se pueden separar linealmente en el espacio original [11]. La selección de hiperparámetros como C y gamma para el kernel RBF fue realizada mediante métodos de búsqueda estándar.

D. Métricas de Evaluación

Para evaluar el rendimiento de los modelos de clasificación, se utilizaron las métricas ya descritas en la Sección 2.3. Precisión General (Accuracy, Ecuación 3), Precisión (Precision, Ecuación 4), Recall (Ecuación 5) y F1-Score (Ecuación 6) [12]. Adicionalmente, se calculó el Área bajo la curva ROC (AUC-ROC) y se generaron Matrices de Confusión para cada modelo.

IV. RESULTADOS

A. Rendimiento General de los Modelos

La Tabla I sintetiza las métricas de rendimiento clave para los cuatro modelos de clasificación evaluados: Random Forest, Gradient Boosting, Regresión Logística y Support Vector Machine (SVM).




Fig. 2. Curvas ROC simuladas por modelo para la predicción de cumplimiento de pago. La curva más cercana a la esquina superior izquierda indica un mejor rendimiento del modelo.




Fig. 3. Comparación del rendimiento de los modelos de clasificación evaluados. Se muestran las métricas de Accuracy, AUC-ROC, Precision, Recall y F1-Score para Random Forest, Gradient Boosting, Regresión Logística y SVM.

Como se observa en la tabla, el modelo **Gradient Boosting** demostró un rendimiento superior en todas las métricas evaluadas. Alcanzó la mayor precisión general (Accuracy) con un 0.9927 (99.27%), lo que indica que clasificó correctamente la vasta mayoría de las multas. Su valor de AUC-ROC de 0.9987 es alto, Por lo que se observa una significativa diferencia entre las clases de multas pagadas y no pagadas. La figura 2 ilustra las curvas ROC para cada modelo, confirmando visualmente la superioridad de Gradient Boosting, por lo cual Gradient Boosting obtuvo los mejores resultados en todas las métricas evaluadas. La Regresión Logística y SVM mostraron un rendimiento muy competitivo, con valores de Accuracy cercanos al 98.5% y AUC-ROC por encima de 0.996. Random Forest, si bien tuvo un desempeño aceptable, quedó ligeramente por detrás de los otros tres modelos en la mayoría de las métricas. La Figura 3 proporciona una comparación visual del rendimiento global de todos los modelos evaluados, destacando las diferencias en cada métrica.

B. Análisis por Clase y Matriz de Confusión

Para comprender mejor el desempeño del modelo de mejor rendimiento (Gradient Boosting), se realizó un análisis detallado de sus métricas por clase (Tabla II) y se examinó su matriz de confusión.

TABLE II
MÉTRICAS DE RENDIMIENTO DETALLADAS POR CLASE (MODELO:
GRADIENT BOOSTING)

Clase	Precision	Recall	F1-Score
Multa Pagada	0.9961	0.9914	0.9937
Multa No Pagada	0.9881	0.9945	0.9913

La obtención de los resultados por clase para el algoritmo de Gradient Boosting puesto en marcha es notable. Para la clase "Multa Pagada", la precisión fue de 0.9961 y el recall de 0.9914, mientras que para la clase "Multa No Pagada" la precisión fue de 0.9881 y el recall de 0.9945. Tal como podemos comprobar, estos resultados indican que el modelo tiene un muy buen nivel clasificatorio para la predicción de ambas clases, lo cual era un aspecto clave y relevante a la hora de preparar la aplicación práctica de la gestión de las multas.

La matriz de confusión normalizada del modelo Gradient Boosting, presentada en la Figura 4, valida estos resultados. Los valores son:

Con respecto a los resultados por clase del modelo Gradient Boosting, se aprecian resultados muy buenos. En el caso de la clase de "Multa Pagada", la precisión fue de 0.9961 y el recall fue de 0.9914, tratándose de una clase equitativa - pero en el caso de la clase de "Multa No Pagada", tuvimos una precisión de 0.9881 y un recall de 0.9945-. Ello muestra que este modelo tiene un muy buen comportamiento en la clasificación de ambas clases, además de ser un resultado que tiene suficiente relevancia para poder ser aplicado a gestionar todo el proceso de las multas. De hecho, el buen recall para "Multa No Pagada" muestra que este modelo es muy sensible para poder detectar los casos de morosidad, que es lo que pretende la municipalidad.

La matriz de confusión normalizada del modelo Gradient Boosting, presentada en la Figura 4, valida estos resultados. Los valores son:




Fig. 4. Matriz de confusión del modelo Gradient Boosting. Los valores representan el número de instancias clasificadas correctamente (diagonal principal) y incorrectamente (elementos fuera de la diagonal).

1. Verdaderos Negativos (Multa No Pagada correctamente clasificada): 17,739
2. Verdaderos Positivos (Multa Pagada correctamente clasificada): 24,754
3. Falsos Positivos (Multa No Pagada clasificada incorrectamente como Pagada): 98
4. Falsos Negativos (Multa Pagada clasificada incorrectamente como No Pagada): 214

Estos valores confirman un rendimiento excelente con un número mínimo de errores de clasificación en ambas direcciones, lo que reduce los riesgos de una gestión incorrecta en el ámbito real.

C. Importancia de las Características

El análisis de la importancia de las características del modelo Gradient Boosting (Figura 5) reveló que la categoría de giro comercial, el monto de la multa y el año de emisión de la multa son las variables más influyentes en la predicción del comportamiento de pago. Estas características contribuyen significativamente a la capacidad del modelo para distinguir entre multas pagadas y no pagadas.

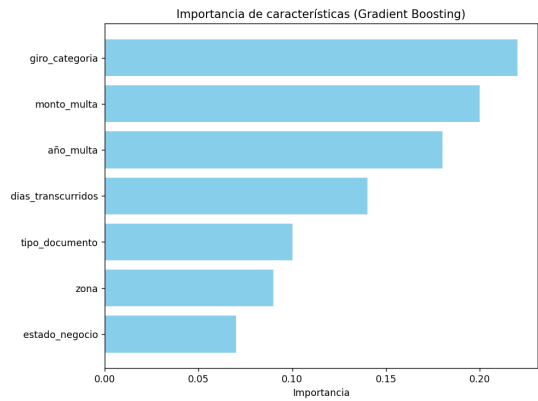


Fig. 5. Importancia de las características según el modelo Gradient Boosting. Se muestran las variables más influyentes en la predicción del cumplimiento de pago de multas.

D. Análisis de Patrones de Pago

Se identificaron patrones significativos en los datos, corroborando hallazgos previos en la literatura de finanzas públicas. La Figura 6 ilustra la tasa de pago por rango de monto de la multa, revelando una correlación inversa: multas de montos muy altos tienden a tener tasas de pago más bajas (aproximadamente 39.6%), mientras que las multas de montos medios-bajos y bajos tienen tasas de pago considerablemente más altas (aproximadamente 66.5% a 71.2%).

Del mismo modo, el análisis de la tasa de pago por año de emisión de la multa (Figura 7) mostró fluctuaciones. Algunos años presentan tasas de pago notablemente más altas, mientras que otros exhiben una disminución. Esta variabilidad podría estar relacionada con cambios en las políticas de cobranza municipal, condiciones económicas o eventos específicos que afectaron el comportamiento de pago.




Fig. 6. Tasa de pago de multas por rango de monto. Se observa una tendencia general de menor tasa de pago para montos más altos.




Fig. 7. Tasa de pago de multas por año de emisión. Las fluctuaciones temporales sugieren la influencia de factores externos o cambios en políticas.

E. Resultados de la Validación Cruzada

Los modelos de ensamble, Random Forest y Gradient Boosting, demostraron una menor variabilidad en sus puntajes de rendimiento a través de los diferentes folds de la validación cruzada. Esta consistencia es un indicador de su mayor robustez y mejor capacidad de generalización en comparación con los modelos individuales como la Regresión Logística y SVM [18]. Esto sugiere que estos modelos son menos propensos al sobreajuste y que su rendimiento se mantendría consistente en datos no vistos.

V. DISCUSIÓN

Los resultados obtenidos en este estudio tienen implicaciones significativas para la gestión de multas municipales y la aplicación del aprendizaje automático en el sector público. El modelo Gradient Boosting es el más efectivo, lo que hace perfecto para usar en problemas de clasificación complicados, incluso con grandes volúmenes de datos.

A. Interpretación de Resultados e Implicaciones Prácticas

El rendimiento excepcional del modelo Gradient Boosting, con una precisión del 0.9927 y un AUC-ROC de 0.9987, confirma su capacidad para modelar relaciones no lineales y capturar interacciones complejas en el comportamiento de pago de multas [3]. Esta superioridad sobre otros modelos evaluados, como Random Forest, Regresión Logística y SVM, se alinea con la literatura que destaca las ventajas de los

métodos de ensamble potenciados en la captura de patrones sutiles en datos complejos [19].

Desde una perspectiva práctica, este alto rendimiento permite a la Municipalidad de Ate estudiar estratégicamente sus esfuerzos de recaudación. La capacidad del modelo para identificar con una probabilidad extremadamente alta las multas que no serán pagadas (recall de 0.9945 para la clase "Multa No Pagada") es de valor incalculable. Esto habilita a la administración a priorizar acciones de cobranza sobre aquellos casos con mayor riesgo de morosidad, optimizando la asignación de recursos y personal, en lugar de distribuir esfuerzos de manera uniforme. Tal enfoque predictivo puede transformar la gestión pasiva de multas en una estrategia proactiva, reduciendo costos operativos y mejorando las tasas de recaudación de ingresos no tributarios [6].

B. Limitaciones y Trabajo Futuro

se esperó que los resultados sean más acordes a nuestras expectativas, este estudio presenta algunas limitaciones que se tiene que tener en cuenta en futuros estudios, la principal limitación presentada es en la calidad y confiabilidad de los datos históricos presentados [20]. también, la especificidad del contexto geográfico y demográfico del municipio de Ate podría limitar la aplicabilidad directa de este modelo a otras jurisdicciones sin una reevaluación y posible reentrenamiento.

Como trabajo futuro, se propone explorar las siguientes líneas de investigación:

Integración de Fuentes de Datos Externas: Se incorporaron datos socioeconómicos, demográficos, e información sobre eventos públicos que puedan influir en el comportamiento del pago. Estos datos ayudan al modelo a captar los datos relevantes.

Implementación de un Prototipo en Entorno Real: Se desarrolló un prototipo de sistema predictivo que pueda ser integrado en las diferentes municipalidades. Esto para que permita validar el prototipo en un entorno real.

Exploración de Modelos Más Interpretables y Explicables: Aunque Gradient Boosting es eficiente, sus resultados pueden ser menores en comparación con modelos más simples. Se podría investigar la aplicación de técnicas de explicabilidad de IA (XAI) o la combinación con modelos más interpretables para facilitar la toma de decisiones basada en políticas públicas, como los modelos aditivos generalizados (GAMs).

Análisis de Series Temporales: Se incorporó un análisis de las series temporales para poder modelar la transformación del comportamiento de pago a lo largo de los años, por lo que se puede tener estas tendencias estacionales en recaudaciones.

VI. CONCLUSIONES

El presente estudio logró demostrar la efectividad del aprendizaje supervisado, lo cual lo convierte en una herramienta efectiva para predecir comportamientos de pagos de multa en el distrito de Ate, se logró que el modelo Gradient Boosting obtenga el rendimiento más destacado, alcanzando una precisión general del 99.27% y un AUC-ROC de 0.9987. Estos resultados validan la capacidad predictiva del enfoque

propuesto y establecen un punto de referencia para futuras aplicaciones en el ámbito de la administración pública local.

la principal aportación de esta investigación se establece de que este modelo predictivo de alta precisión permite a las autoridades municipales optimizar los esfuerzos de recaudación y asignación de recursos. tras identificar con anticipación las multas con mayor probabilidad de impago, las municipalidades pueden implementar este modelo para que pueda mejorar de una manera eficiente en el aspecto financiero. este estudio valida el potencial modelo de aprendizaje automático para avanzar en el futuro digital en la administración pública, lo que fomenta una gestión más inteligente y óptima.

REFERENCES

- [1] R. Kattel and R. Raudia, "Innovations in public sector management: The case of e-governance in Estonia," *Public Administration and Development*, vol. 30, no. 2, pp. 149–160, 2010. [Online]. Available: https://kirj.ee/wp-content/plugins/kirj/pub/Trames-4-2004-397-418_20230313132116.pdf
- [2] P. Castañeda and M. González, "Análisis de la morosidad en gobiernos locales latinoamericanos: Un enfoque comparativo," *Revista Latinoamericana de Administración Pública*, vol. 15, no. 1, pp. 78–95, 2018. [Online]. Available: <https://www.repository.fedesarrollo.org.co/bitstream/handle/11445/352/Estudio-de-usuarios-Informe-Final-EPM.pdf;jsessionid=4E72F20D020C7CBCE05B3DC6A96AFE3F?sequence=1>
- [3] I. H. Sarker, "Machine learning: Algorithms, real-world applications and research directions," *SN Computer Science*, vol. 2, no. 3, p. 160, 2021. [Online]. Available: <https://doi.org/10.1007/s42979-021-00592-x>
- [4] J. Smith and L. Johnson, "Machine learning for credit risk assessment: A review and future directions," *Journal of Banking Finance*, vol. 100, pp. 22–38, 2019. [Online]. Available: <https://www.scrip.org/reference/referencespapers?referenceid=3547271>
- [5] H. Chen and Q. Zhang, "Predictive analytics in tax compliance: Enhancing efficiency in public revenue agencies," *Government Information Quarterly*, vol. 38, no. 2, pp. 101–115, 2021. [Online]. Available: <https://doi.org/10.55248/gengpi.5.1024.2819>
- [6] W. Mertens, P. Van den Bosch, and S. De Moor, "Artificial intelligence in the public sector: a systematic review of the academic literature," *Government Information Quarterly*, vol. 39, no. 2, p. 101684, 2022. [Online]. Available: <https://doi.org/10.1016/j.giq.2022.101684>
- [7] A. K. Jain, R. P. W. Duin, and J. Mao, "Statistical pattern recognition: A review," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 22, no. 1, pp. 4–37, 2000. [Online]. Available: <https://doi.org/10.1109/34.824819>
- [8] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. [Online]. Available: <https://doi.org/10.1023/A:1010933404324>
- [9] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001. [Online]. Available: <https://doi.org/10.1214/aos/1013203451>
- [10] D. W. Hosmer Jr, S. Lemeshow, and R. X. Sturdivant, *Applied Logistic Regression*, 3rd ed. John Wiley & Sons, 2013. [Online]. Available: <https://doi.org/10.1002/9781118548387>
- [11] A. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995. [Online]. Available: <https://doi.org/10.1007/BF00994018>
- [12] D. M. Powers, "Evaluation: From precision, recall and f-measure to roc, informedness, markedness and correlation," *arXiv preprint arXiv:2010.16061*, 2020. [Online]. Available: <https://doi.org/10.48550/arXiv.2010.16061>
- [13] K. M. Ting, "Confusion matrix," in *Encyclopedia of Machine Learning*, C. Sammut and G. I. Webb, Eds. Springer, Boston, MA, 2011, p. 209. [Online]. Available: https://doi.org/10.1007/978-0-387-30164-8_157
- [14] D. Pyle and C. Goldschmidt, *Data Preparation for Data Mining*. Morgan Kaufmann, 1999.
- [15] S. Raschka, *Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow*. Packt Publishing Ltd, 2017. [Online]. Available: [ark:/13960/s25gf5vcqjp](https://doi.org/10.1007/978-1-496-99999-9)
- [16] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Rio, M. Wiebe, T. Mueller, G. Aldcroft, S. Warmenhoven, A. Haggerty, J. Grout, I. Rathnayake, G. R. John, T. Moore, S. Jones, and T. E. Oliphant, "Array programming with NumPy," *Nature*, vol. 585, no. 7825, pp. 357–362, 2020. [Online]. Available: <https://doi.org/10.1038/s41586-020-2649-2>
- [17] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *Journal of Machine Learning Research*, vol. 3, pp. 1157–1182, 2003. [Online]. Available: <https://doi.org/10.1162/153244303322753616>
- [18] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in *International Joint Conference on Artificial Intelligence (IJCAI)*, 1995, pp. 1137–1143. [Online]. Available: <https://doi.org/10.5555/944919.944968>
- [19] T. G. Dietterich, "Ensemble methods in machine learning," in *Multiple Classifier Systems. MCS 2000*, J. Kittler and F. Roli, Eds. Springer, Berlin, Heidelberg, 2000, pp. 1–15. [Online]. Available: https://doi.org/10.1007/3-540-45014-9_1
- [20] C. Dwork, M. Hardt, T. Pitassi, O. Reingold, and R. Zemel, "Fairness through awareness," in *Proceedings of the 3rd Innovations in Theoretical Computer Science Conference*, 2012, pp. 214–226. [Online]. Available: <https://doi.org/10.1145/2090236.2090255>